

# TD3 Saisonnalité

Florian Crochet, Isaline Hervé

## Sommaire

<b>Développements et simulation de modèles saisonniers</b>	<b>3</b>
Développement, type de modèle et nombre de coefficients à estimer . . . . .	3
Première équation . . . . .	3
Deuxième équation . . . . .	3
Troisième équation . . . . .	4
Questions . . . . .	4
1. . . . .	5
Premier modèle . . . . .	5
Deuxième modèle . . . . .	7
Troisième modèle . . . . .	9
2. . . . .	11
Premier modèle . . . . .	11
Deuxième modèle . . . . .	13
Troisième modèle . . . . .	14
3. . . . .	16
Premier modèle . . . . .	16
Deuxième modèle . . . . .	17
Troisième modèle . . . . .	18
<b>Analyse d'une série temporelle saisonnière : la consommation de gaz naturel en France (2008-2024)</b>	<b>21</b>
Import des données . . . . .	21
Transformation en série temporelle . . . . .	21
Visualisation de la série temporelle . . . . .	21
Observation des autocorrélogrammes et caractéristiques . . . . .	22
Modélisation de la série . . . . .	24
Modèle - 1 - auto.arima . . . . .	24
Modèle Arima - aléatoire 1 . . . . .	27
Modèle Arima - 2 . . . . .	29

Comparaison des modèles . . . . .	31
Tableau de comparaison de critères d'informations : . . . . .	32
<b>Analyse d'une série temporelle saisonnière avec tendance linéaire : la fréquentation de l'aéroport Toulouse-Blagnac (1993-2008)</b>	<b>33</b>
1. Chargement de la base de données . . . . .	33
2. Décomposition de la série . . . . .	34
3. Questions . . . . .	34
4. Suppression de la tendance . . . . .	35
5. Modélisation en recourant à la différenciation saisonnière . . . . .	35
1. Différenciation . . . . .	35
2. Autocorrélogrammes . . . . .	36
3. Série filtrée via un SARIMA(1, 0, 1)(1, 0, 1) <sub>12</sub> et comportement des résidus	38
4. Série filtrée via un SARIMA(3, 0, 3)(1, 0, 1) <sub>12</sub> et comportement des résidus	40
5. Série filtrée via un SARIMA(3, 0, 2)(0, 0, 1) <sub>12</sub> et comportement des résidus	46
6. Conclusion . . . . .	48
6. Modélisation en utilisant un modèle de type saisonnier . . . . .	48
1. Modèle différenciation saisonnière d'ordre 1 . . . . .	48
2. Série filtrée via un SARIMA(1, 0, 1)(1, 1, 1) <sub>12</sub> et comportement des résidus	50
3. Série filtrée via un SARIMA(3, 0, 3)(1, 1, 1) <sub>12</sub> et comportement des résidus	52
4. Série filtrée via un SARIMA(3, 0, 2)(1, 1, 1) <sub>12</sub> et comportement des résidus	56
5. Conclusion . . . . .	58
7. Comparaison des résultats de ces deux modèles . . . . .	58
1. Modèles . . . . .	58
2. Autocorrélogrammes : ACF . . . . .	59
3. Autocorrélogrammes partiels : PACF . . . . .	61
6. Conclusion . . . . .	62
8. Conclusion . . . . .	62
1. On sépare notre tendance en deux périodes de temps. . . . .	62
2. On sépare notre modèle en deux périodes de temps. . . . .	66
Series finales . . . . .	68

## Développements et simulation de modèles saisonniers

### Développement, type de modèle et nombre de coefficients à estimer

#### Première équation

$$Y_t = \frac{(1 + \theta_1 L + \theta_2 L^2)(1 + \Theta_1 L^4)}{(1 - \phi_1 L)(1 - \Phi_1 L^4)} \varepsilon_t$$

Il s'agit d'un modèle SARMA(1, 2)(1, 1)<sub>4</sub>.

En développant, on obtient :

$$Y_t = \frac{1 + \theta_1 L + \theta_2 L^2 + \Theta_1 L^4 + \theta_1 \Theta_1 L^5 + \theta_2 \Theta_1 L^6}{1 - \phi_1 L - \Phi_1 L^4 + \phi_1 \Phi_1 L^5} \varepsilon_t$$

Le modèle est de type ARMA(5, 6) avec 2 coefficients AR et 1 coefficient MA nuls, soit 8 coefficients à estimer.

#### Deuxième équation

$$Y_t = \frac{(1 + \theta_1 L)(1 + \Theta_1 L^6)}{(1 - \phi_1 L)(1 - \Phi_1 L^6)} \varepsilon_t$$

Il s'agit d'un modèle SARMA(1, 1)(1, 1)<sub>6</sub>.

En développant, on obtient :

$$Y_t = \frac{1 + \theta_1 L + \Theta_1 L^6 + \theta_1 \Theta_1 L^7}{1 - \phi_1 L - \Phi_1 L^6 + \phi_1 \Phi_1 L^7} \varepsilon_t$$

Le modèle est de type ARMA(7, 7) avec 4 coefficients AR et 4 coefficients MA nuls, soit 6 coefficients à estimer.

### Troisième équation

$$Y_t = \frac{(1 + \Theta_1 L^{12})}{(1 - \phi_1 L - \phi_2 L^2)} \varepsilon_t$$

Il s'agit d'un modèle SARMA(2, 0)(0, 1)<sub>12</sub>.

Ce modèle est également de type ARMA(2, 12) avec 0 coefficient AR et 11 coefficients MA nuls, soit 3 coefficients à estimer.

### Questions

```
library(astsa)
library(forecast)
```

Warning: package 'forecast' was built under R version 4.4.3

```
Registered S3 method overwritten by 'quantmod':
method           from
as.zoo.data.frame zoo
```

Attaching package: 'forecast'

The following object is masked from 'package:astsa':

gas

```
library(tidyverse)
```

Warning: package 'tidyverse' was built under R version 4.4.3

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr     1.1.4     v readr     2.1.5
vforcats   1.0.0     v stringr   1.5.1
v ggplot2   3.5.1     v tibble    3.2.1
v lubridate 1.9.4     v tidyverse 1.3.1
v purrr    1.0.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to becom
```

1.

### Premier modèle

```
set.seed(123)
```

Pour commencer, nous allons définir des coefficients :

```
ar_coef <- c(0.4)
ma_coef <- c(0.3, 0.3)
sar_coef <- c(0.4)
sma_coef <- c(0.3)
saisonnalite <- 4
```


Simulation du modèle SARMA(1,2)(1,1)[4] :

```
sarma1 <- sarima.sim(ar = ar_coef, ma = ma_coef,
                      sar = sar_coef, sma = sma_coef,
                      S = saisonnalite, n = 500)
```

Affichage de la série temporelle et des autocorrélogrammes :



```
par(mfrow=c(1,1))
ts.plot(sarma1, main="Simulation d'un SARMA(1,2)(1,1)[4]", ylab="Valeurs", col="royalblue")
```

## Simulation d'un SARMA(1,2)(1,1)[4]



Cette série montre des fluctuations importantes, avec notamment un pic positif important au milieu du temps représenté.

```
par(mfrow=c(1,2))
Acf(sarma1, main = "ACF - SARMA(1,2)(1,1)[4]")
Pacf(sarma1, main = "PACF - SARMA(1,2)(1,1)[4]")
```

**ACF – SARMA(1,2)(1,1)[4]****PACF – SARMA(1,2)(1,1)[4]**

En ce qui concerne l'ACF de cette série, nous observons une décroissance quasiment exponentielle, ce qui était attendue, sauf pour le retard 4. Les retards significatifs sur le PACF alternent entre valeurs positives et négatives et décroissent, mais seulement après le 3ème retard, ce qui n'est pas logique par rapport à la série.

### Deuxième modèle

```
set.seed(123)
```

Définition des coefficients :


```
ar_coef <- c(0.4)
ma_coef <- c(0.4)
sar_coef <- c(0.4)
sma_coef <- c(0.4)
saisonnalite <- 6
```

Simulation du modèle SARMA(1,1)(1,1)[6] :

```
sarma2 <- sarima.sim(ar = ar_coef, ma = ma_coef,
                      sar = sar_coef, sma = sma_coef,
                      S = saisonnalite, n = 500)
```



Affichage de la série temporelle et des autocorrélogrammes :

```
par(mfrow=c(1,1))
ts.plot(sarma2, main="Simulation d'un SARMA(1,1)(1,1)[6]", ylab="Valeurs", col="darkred")
```



Comme pour la série précédente, nous n'observons pas de tendance marquée mais une présence de saisonnalité, avec divers chocs positifs et négatifs à certaines périodes de temps.

```
par(mfrow=c(1,2))
Acf(sarma2, main = "ACF - SARMA(1,1)(1,1)[6]")
Pacf(sarma2, main = "PACF - SARMA(1,1)(1,1)[6]")
```

**ACF – SARMA(1,1)(1,1)[6]****PACF – SARMA(1,1)(1,1)[6]**

L'ACF et le PACF ne suivent pas les attentes envers les autocorrélogrammes pour une série avec ces caractéristiques. En effet, l'ACF ne décroît pas exponentiellement et pour le PACF, l'alternance entre valeurs positives et négatives et la baisse de la significativité des coéfficient sont irrégulières.

### Troisième modèle

```
set.seed(123)
```

Définition des coefficients :


```
ar_coef <- c(0.6, 0.3)
ma_coef <- c(0)
sar_coef <- c(0)
sma_coef <- c(0.8)
saisonnalite <- 12
```

Simulation du modèle SARMA(2,0)(0,1)[12] :

```
sarma3 <- sarima.sim(ar = ar_coef, ma = ma_coef,
                      sar = sar_coef, sma = sma_coef,
                      S = saisonnalite, n = 500)
```

Affichage de la série temporelle et des autocorrélogrammes :


```
par(mfrow=c(1,1))
ts.plot(sarma3, main="Simulation d'un SARMA(2,0)(0,1)[12]", ylab="Valeurs", col="royalblue")
```




D'après la représentation graphique de cette série, nous constatons que les valeurs fluctuent beaucoup, mais sans tendance générale présente sur toute la durée du temps défini.

```
par(mfrow=c(1,2))
Acf(sarma3, main = "ACF - SARMA(2,0)(0,1)[12]")
Pacf(sarma3, main = "PACF - SARMA(2,0)(0,1)[12]")
```

**ACF – SARMA(2,0)(0,1)[12]**



**PACF – SARMA(2,0)(0,1)[12]**



L'ACF de la série semble globalement suivre un décroissement exponentielle en termes de significativité des retards. Néanmoins, le PACF montre une irrégularité dans l'alternance du signe de ses coefficients ainsi que dans la décroissance de ses valeurs.

## 2.

### Premier modèle


Ajustement du modèle SARMA(1,2)(1,1)[4] :

```
mod_sarma1 <- Arima(sarma1, order = c(1,0,2), seasonal = list(order = c(1,0,1), period = 4))
```

Autocorréogrammes des résidus :


```
Acf(residuals(mod_sarma1), main="ACF des résidus - SARMA(1,2)(1,1)[4] ")
```

### ACF des résidus – SARMA(1,2)(1,1)[4]



```
Pacf(residuals(mod_sarma1), main="PACF des résidus – SARMA(1,2)(1,1)[4] ")
```

### PACF des résidus – SARMA(1,2)(1,1)[4]



Les autocorréogrammes des résidus de cette modélisation ne montrent pas de retards significatifs. Alors, les résidus peuvent être considérés comme des bruits blancs.


## Deuxième modèle

Ajustement du modèle SARMA(1,1)(1,1)[6] :


```
mod_sarma2 <- Arima(sarma2, order = c(1,0,1), seasonal = list(order = c(1,0,1), period = 6))
```

Autocorrélogrammes des résidus :

```
Acf(residuals(mod_sarma2), main="ACF des résidus - SARMA(1,1)(1,1)[6]")
```



```
Pacf(residuals(mod_sarma2), main="PACF des résidus - SARMA(1,1)(1,1)[6]")
```



D'après l'ACF et le PACF des résidus de ce modèle, nous pouvons également conclure que les résidus correspondent à un bruit blanc, puisqu'aucun retard n'est significatif.

### Troisième modèle


Ajustement du modèle SARMA(2,0)(0,1)[12] :

```
mod_sarma3 <- Arima(sarma3, order = c(2,0,0), seasonal = list(order = c(0,0,1), period = 12))
```

Autocorrélogrammes des résidus :


```
Acf(residuals(mod_sarma3), main="ACF des résidus - SARMA(2,0)(0,1)[12]")
```

### **ACF des résidus – SARMA(2,0)(0,1)[12]**



```
Pacf(residuals(mod_sarma3), main="PACF des résidus – SARMA(2,0)(0,1)[12] ")
```

### **PACF des résidus – SARMA(2,0)(0,1)[12]**



En observant l'ACF et le PACF des résidus pour cette modélisation, nous constatons que le

lag 15 est très légèrement significatif. Alors, le fait que les résidus correspondent à des bruits blancs n'est pas assuré et reste à vérifier, comme avec un test de Ljung-Box par exemple.

### 3.

Afin de trouver dans chacun des cas d'autres façons de modéliser le processus simulé permettant d'obtenir des bruits blancs, nous nous sommes aidé des équations développées précédemment. En effet, nous avions trouvé des correspondances avec des modèles ARMA que nous avons alors modélisé.


#### Premier modèle

Ajustement du modèle ARMA(5,6) :


```
mod_sarma4 <- Arima(sarma1, order = c(5,0,6), seasonal = list(order = c(0,0,0)))
```

Autocorrélogrammes des résidus :

```
Acf(residuals(mod_sarma4), main="ACF des résidus - ARMA(5,6)")
```



```
Pacf(residuals(mod_sarma4), main="PACF des résidus - ARMA(5,6)")
```



### Deuxième modèle


Ajustement du modèle ARMA(7,7) :

```
mod_sarma5 <- Arima(sarma2, order = c(7,0,7), seasonal = list(order = c(0,0,0)))
```

Autocorréogrammes des résidus :


```
Acf(residuals(mod_sarma5), main="ACF des résidus - ARMA(7,7)")
```

### ACF des résidus – ARMA(7,7)



```
Pacf(residuals(mod_sarma5), main="PACF des résidus - ARMA(7,7)")
```

### PACF des résidus – ARMA(7,7)




Troisième modèle

Ajustement du modèle ARMA(2,12) :

```
mod_sarma6 <- Arima(sarma3, order = c(2,0,12), seasonal = list(order = c(0,0,0)))
```


Autocorrélogrammes des résidus :

```
Acf(residuals(mod_sarma6), main="ACF des résidus - ARMA(2,12)")
```



```
Pacf(residuals(mod_sarma6), main="PACF des résidus - ARMA(2,12)")
```

### PACF des résidus – ARMA(2,12)



Pour ces 3 modèles, nous n'observons aucun retard significatifs au niveau de l'ACF ou du PACF des résidus. Alors, nous pouvons affirmer que les résidus sont bien de type bruit blanc.

# Analyse d'une série temporelle saisonnière : la consommation de gaz naturel en France (2008-2024)

## Import des données

```
load("data/fr_gas_consumption_monthly.RData")
```


## Transformation en série temporelle

```
gas_ts <- ts(gas_consumption$consumption, start = c(2008, 1), frequency = 12)
```

## Visualisation de la série temporelle

```
par(mfrow=c(1,1))
plot.ts(gas_ts, main="Consommation de gaz naturel en France (2008-2024)", col="royalblue", x
```

## Consommation de gaz naturel en France (2008–2024)




D'après la représentation de cette série temporelle, nous pouvons constater une saisonnalité marquée, ce qui semble logique étant donné que les données représentent la consommation de

gaz naturel. En effet, cela fait sens qu'il y est une augmentation de la consommation de gaz en hiver, et une baisse en été, chaque année. De plus, comme décrit dans l'énoncé, nous n'observons pas de tendance évidente.

### Observation des autocorrélogrammes et caractéristiques


```
Acf(gas_ts, main="Autocorrélogramme de la consommation de gaz")
```

**Autocorrélogramme de la consommation de gaz**



```
Pacf(gas_ts, main="Autocorrélogramme de la consommation de gaz")
```

## Autocorréogramme de la consommation de gaz




Nous pouvons voir que l'ACF montre des pics tous les 12 mois. Cela confirme donc la forte saisonnalité annuelle supposé précédemment.

Ensuite, le premier retard significatif positif en PACF suggère une composante AR. Puis, on observe une alternance de signes dans les retards suivants, ce qui évoque la présence d'un processus oscillatoire, sûrement lié à des effets saisonniers.

```
decompo <- decompose(gas_ts)
plot(decompo)
```

## Decomposition of additive time series



En décomposant la série comme présenté ci-dessus, nous pouvons voir que la tendance semble complexe et évoluant négativement, nous ne la prendrons donc pas en compte dans la modélisation. D'après la forte saisonnalité qui semble ressortir de cette série, nous pouvons alors essayer d'estimer un modèle SARIMA.

## Modélisation de la série

### Modèle - 1 - auto.arima

```
# Ajustement automatique d'un modèle SARIMA avec saisonnalité à partir de la fonction auto.arima
mod_sarima_1 <- auto.arima(gas_ts, seasonal = TRUE, d=0)

summary(mod_sarima_1)
```

Series: gas\_ts  
ARIMA(1,0,0)(0,1,1)[12] with drift

Coefficients:

	ar1	sma1	drift
0.3966	-0.8324	-158.1512	
s.e.	0.0698	0.0636	46.7161

```

sigma^2 = 331445867: log likelihood = -2116.59
AIC=4241.17    AICc=4241.39    BIC=4254.12

```

Training set error measures:


ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set 188.366	17509.64	12552.9	0.311602	9.436687	0.7147071	-0.05269679

La fonction auto.arima, en précisant que la tendance est nulle, nous donne donc le modèle suivant : ARIMA(1,0,0)(0,1,1)[12], correspondant notamment bien en termes de nombre de retards (12).

Nous pouvons observer les autocorrélogrammes suivant pour cette série :


```
Acf(residuals(mod_sarima_1), main="ACF des résidus - SARIMA(1,0,0)(0,1,1)[12]")
```

### **ACF des résidus – SARIMA(1,0,0)(0,1,1)[12]**



```
Pacf(residuals(mod_sarima_1), main="PACF des résidus - SARIMA(1,0,0)(0,1,1)[12]")
```

## ACF des résidus – SARIMA(1,0,0)(0,1,1)[12]



Graphiquement, nous constatons que 2 retards sont légèrement significatifs au niveau de l'ACF, montrant que les résidus peuvent presque être considérés comme des bruits blancs. Au niveau du PACF, un seul retard sera significatif.

Test de Ljung-Box :

```
Box.test(residuals(mod_sarima_1), lag=20, type="Ljung-Box")
```

Box-Ljung test

```
data: residuals(mod_sarima_1)
X-squared = 20.415, df = 20, p-value = 0.4322
```

Après cela, en observant la p-value du test de Ljung-Box, nous constatons qu'êtant supérieure à 0.05, les résidus peuvent être considérés comme représentant du bruit blanc, ainsi le modèle est valide.

Nous avons également testé d'autres modélisation pour cette série temporelle.

## Modèle Arima - aléatoire 1

Pour cet essai, afin que la modélisation corresponde à la série de consommation de gaz naturel, nous avons précisé que le nombre de retard devait être 12, que la tendance est inexistant et que la saisonnalité existe.

```
mod_sarima_2 <- Arima(gas_ts, order=c(1,0,1), seasonal=list(order=c(1,1,0), period=12))
summary(mod_sarima_2)
```

Series: gas\_ts  
ARIMA(1,0,1)(1,1,0) [12]

Coefficients:

	ar1	ma1	sar1
ar1	0.7414	-0.4934	-0.5135
s.e.	0.1785	0.2381	0.0625

sigma^2 = 415568223: log likelihood = -2132.6  
AIC=4273.2 AICc=4273.42 BIC=4286.14


Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-2050.276	19606.14	13737.42	-2.445719	10.14451	0.7821483
ACF1						
Training set	-0.006297488					

Autocorréogrammes :


```
Acf(residuals(mod_sarima_2), main="ACF - Résidus SARIMA(1,0,1)(1,1,0) [12] ")
```

### ACF – Résidus SARIMA(1,0,1)(1,1,0)[12]



```
Pacf(residuals(mod_sarima_2), main="PACF – Résidus SARIMA(1,0,1)(1,1,0)[12]")
```

### PACF – Résidus SARIMA(1,0,1)(1,1,0)[12]



En observant l'ACF et le PACF, nous pouvons voir que certains lags sont significatifs, les résidus semblent alors ne pas être des bruits blancs.

Test de Ljung-Box :

```
Box.test(residuals(mod_sarima_2), lag=20, type="Ljung-Box")
```

```
Box-Ljung test
```

```
data: residuals(mod_sarima_2)
X-squared = 28.429, df = 20, p-value = 0.09963
```

La p-value du test de Ljung-Box est ici inférieure à 0.05, ce qui montre qu'il reste de l'autocorrélation et que les résidus ne peuvent pas être considérés comme du bruit blanc. La série peut alors être améliorée.

## Modèle Arima - 2

Ensuite, nous avons modélisé la série d'une autre façon. Comme pour les cas précédents, nous avons veillé à ce que le nombre de retard soit de 12, que la tendance soit nulle et la saisonnalité existante.

```
mod_sarima_3 <- Arima(gas_ts, order=c(2,0,0), seasonal=list(order=c(0,2,4), period=12))
summary(mod_sarima_3)
```

```
Series: gas_ts
ARIMA(2,0,0)(0,2,4) [12]
```

Coefficients:

	ar1	ar2	sma1	sma2	sma3	sma4
0.3198	0.1588	-1.9317	1.0058	-0.0975	0.0620	
s.e.	0.0769	0.0783	0.3793	0.3957	0.1720	0.1021

```
sigma^2 = 314133304: log likelihood = -2011.67
AIC=4037.34    AICc=4038    BIC=4059.53
```

Training set error measures:


	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-855.5325	16340.54	11206.21	-1.709675	8.492213	0.6380323

ACF1

Training set -0.01536498


Autocorréogrammes :

```
Acf(residuals(mod_sarima_3), main="ACF - Résidus SARIMA(2,0,0)(0,2,4)[12]")
```



```
Pacf(residuals(mod_sarima_3), main="PACF - Résidus SARIMA(2,0,0)(0,2,4)[12]")
```

## PACF – Résidus SARIMA(2,0,0)(0,2,4)[12]



D'après les autocorrélogrammes de cette modélisation, nous observons seulement un retard très légèrement significatif dans l'ACF. Alors, les résidus de la série peuvent certainement être considérés comme des bruits blancs.

Test de Ljung-Box :

```
Box.test(residuals(mod_sarima_3), lag=20, type="Ljung-Box")
```

```
Box-Ljung test

data: residuals(mod_sarima_3)
X-squared = 17.298, df = 20, p-value = 0.6336
```

Cela est confirmé par le test de Ljung-Box, car avec une p-value > 0.05, le modèle est valide et les résidus montrent du bruit blanc.

### Comparaison des modèles

Pour commencer, le 2ème modèle étant le seul à avoir une p-value < à 0.05 au test de Ljung-Box, nous pouvons écarter ce modèle.

Du point de vue graphique, d'après les autocorrélogrammes produits ci-dessus, le meilleur modèle semble être le 3ème. En effet, c'est le modèle ayant le moins de coefficients significatifs sur ses autocorrélogrammes.

De plus, nous pouvons également observer les critères d'informations afin de voir envers quel modèle sont-ils favorables.

**Tableau de comparaison de critères d'informations :**

```
table_comparaison <- data.frame(
  Model = c("SARIMA(1,0,0)(0,1,1)[12]",
            "SARIMA(1,0,1)(1,1,0)[12]",
            "SARIMA(2,0,0)(0,2,4)[12]"),
  AIC = c(AIC(mod_sarima_1), AIC(mod_sarima_2), AIC(mod_sarima_3)),
  BIC = c(BIC(mod_sarima_1), BIC(mod_sarima_2), BIC(mod_sarima_3))
)

print(table_comparaison)
```

	Model	AIC	BIC
1	SARIMA(1,0,0)(0,1,1)[12]	4241.171	4254.117
2	SARIMA(1,0,1)(1,1,0)[12]	4273.197	4286.143
3	SARIMA(2,0,0)(0,2,4)[12]	4037.338	4059.532

D'après l'AIC et le BIC de ces modèles, c'est également le modèle 3 qui semble être le plus optimal, avec un AIC et BIC plus faibles que pour les autres modèles.

## Analyse d'une série temporelle saisonnière avec tendance linéaire : la fréquentation de l'aéroport Toulouse-Blagnac (1993-2008)

### 1. Chargement de la base de données


```
# Chargement
load("data/tls_monthly_passengers.rda")

# Vérification
str(trafmensu)
```

Time-Series [1:178] from 1993 to 2008: 246 238 263 278 287 ...

```
# Affichage
plot(
  trafmensu,
  main = "Fréquentation de l'aéroport Toulouse-Blagnac (1993-2008)"
)
```


### Fréquentation de l'aéroport Toulouse-Blagnac (1993–2008)



## 2. Décomposition de la série

```
# Décomposition
decomp_trafmensu <- decompose(
  trafmensu,
  type = "additive" # car l'amplitude des variations saisonnières est constante au fil du temps
)

# Affichage
plot(decomp_trafmensu)
```



## 3. Questions

En observant la décomposition, nous remarquons une cassure de la tendance en 2001 due aux attentats du 11 septembre. La tendance est donc différente après 2001. Il est plus pertinent de réaliser une modélisation avant 2001 et une après 2001.


De plus, nous observons des motifs réguliers dans la série des résidus, ce qui indique la présence d'autocorrélation.

Nous devons donc retirer la tendance de la série et estimer la série sans tendance grâce à un modèle SARIMA.

#### 4. Suppression de la tendance

```
# Série sans tendance
trafmensu_sans_t <- trafmensu - decomptrafmensu$trend

# Affichage
plot(
  trafmensu_sans_t,
  main = "Série sans tendance"
)
```



#### 5. Modélisation en recourant à la différenciation saisonnière


##### 1. Différenciation

```
d_trafmensu_sans_t <- diff(
  trafmensu_sans_t,
  lag = 12)

plot(
```

```
d_trafmensu_sans_t,  
main = "Série avec différenciation saisonnière"  
)
```

## Série avec différenciation saisonnière




## 2. Autocorrélogrammes

```
d_trafmensu_sans_t |>  
ggAcf(lag.max = 48) +  
scale_x_continuous(breaks = seq(0, 48, by = 4)) +  
theme_bw()
```

Scale for x is already present.  
Adding another scale for x, which will replace the existing scale.


Series: d\_trafmensu\_sans\_t



```
d_trafmensu_sans_t |>
  ggPacf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  theme_bw()
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.



Nous allons essayer de déterminer les paramètres  $p$ ,  $q$ ,  $P$  et  $Q$  du modèle SARIMA( $p, 0, q$ )( $P, 0, Q$ )<sub>12</sub> en fonction des graphiques de l'ACF et de la PACF.

L'ACF est significativement non nulle jusqu'au retard 1, donc  $q = 1$ . L'ACF est significativement non nulle jusqu'au retard saisonnier 1 ( $1 \times 12$ ), donc  $Q = 1$ .

La PACF est significativement non nulle jusqu'au retard 1, donc  $p = 1$ . La PACF est significativement non nulle jusqu'au retard saisonnier 1 ( $3 \times 12$ ), donc  $P = 1$ .

Nous obtenons un modèle SARIMA(1, 0, 1)(1, 0, 1)<sub>12</sub>

### 3. Série filtrée via un SARIMA(1, 0, 1)(1, 0, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_d_trafmensu_sans_t <- Arima(
  d_trafmensu_sans_t,
  order = c(1,0,1),
  seasonal = list(order = c(1,0,1), period = 12)
)

# Autocorrélogrammes
acf_sarima1 <- sarima_d_trafmensu_sans_t$residuals |>
  ggAcf(lag.max = 48) +
```

```

scale_x_continuous(breaks = seq(0, 48, by = 4))+
ggtitle("ACF des résidus du modèle SARIMA(1, 0, 1)(1, 0, 1)(12)") +
theme_bw() +
theme(plot.title = element_text(hjust = 0.5))

```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.

```


pacf_sarima1 <- sarima_d_trafmensu_sans_t$residuals |>
ggPacf(lag.max = 48) +
scale_x_continuous(breaks = seq(0, 48, by = 4)) +
ggtitle("PACF des résidus du modèle SARIMA(1, 0, 1)(1, 0, 1)(12)") +
theme_bw() +
theme(plot.title = element_text(hjust = 0.5))

```


Scale for x is already present.

Adding another scale for x, which will replace the existing scale.

```
acf_sarima1
```



```
pacf_sarima1
```



Graphiquement, les résidus ne suivent pas un bruit blanc et présentent encore des autocorrélations.

Nous allons essayer de déterminer d'autres paramètres p, q, P et Q du modèle SARIMA(p, 0, q)(P, 0, Q)<sub>12</sub> en fonction des graphiques de l'ACF et de la PACF sur les résidus du modèle.

L'ACF est significativement non nulle au retard 3, donc q = 3. La PACF est significativement non nulle retard 3, donc p = 3.

#### 4. Série filtrée via un SARIMA(3, 0, 3)(1, 0, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_d_trafmensu_sans_t2 <- Arima(
  d_trafmensu_sans_t,
  order = c(3,0,3),
  seasonal = list(order = c(1,0,1), period = 12)
)

# Autocorrélogrammes
acf_sarima2 <- sarima_d_trafmensu_sans_t2$residuals |>
```

```

ggAcf(lag.max = 48) +
scale_x_continuous(breaks = seq(0, 48, by = 4)) +
ggtitle("ACF des résidus du modèle SARIMA(3, 0, 3)(1, 0, 1)(12)") +
theme_bw() +
theme(plot.title = element_text(hjust = 0.5))

```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.

```


pacf_sarima2 <- sarima_d_trafmensu_sans_t2$residuals |>
ggPacf(lag.max = 48) +
scale_x_continuous(breaks = seq(0, 48, by = 4)) +
ggtitle("ACF des résidus du modèle SARIMA(3, 0, 3)(1, 0, 1)(12)") +
theme_bw() +
theme(plot.title = element_text(hjust = 0.5))

```

Scale for x is already present.


Adding another scale for x, which will replace the existing scale.

acf\_sarima2



```
pacf_sarima2
```

ACF des résidus du modèle SARIMA(3, 0, 3)(1, 0, 1)(12)



Les résidus suivent un bruit blanc et ne devraient pas présenter d'autocorrélation.

Nous testons la nullité des paramètres estimés pour les différents retards, ainsi que la présence d'autocorrélations significatives à l'aide du test de Ljung-Box.

```
# Test de Ljung-Box sur les résidus pour les 48 premiers lags

resultat_Ljung_Box <- tibble(
  lag = 1:48
) |>
  mutate(
    test_result = map(
      lag,
      ~ Box.test(
        residuals(sarima_d_trafmensu_sans_t2),
        lag = .x,
        type = "Ljung-Box"
      )
    ),
    X_squared = map_dbl(test_result, ~ .x$statistic),
    df = map_dbl(test_result, ~ .x$parameter),
```

```

p_value = map_dbl(test_result, ~ .x$p.value),
significativite = ifelse(
  p_value < 0.1,
  "Rejet de H0",
  "Non-rejet de H0"
)
) |>
select(lag, X_squared, df, p_value, significativite)

print(resultat_Ljung_Box, n = 48)

```

	lag	X_squared	df	p_value	significativite
	<int>	<dbl>	<dbl>	<dbl>	<chr>
1	1	0.00217	1	0.963	Non-rejet de H0
2	2	0.0219	2	0.989	Non-rejet de H0
3	3	0.101	3	0.992	Non-rejet de H0
4	4	0.242	4	0.993	Non-rejet de H0
5	5	0.627	5	0.987	Non-rejet de H0
6	6	0.742	6	0.994	Non-rejet de H0
7	7	0.842	7	0.997	Non-rejet de H0
8	8	1.16	8	0.997	Non-rejet de H0
9	9	1.16	9	0.999	Non-rejet de H0
10	10	3.52	10	0.966	Non-rejet de H0
11	11	3.72	11	0.977	Non-rejet de H0
12	12	3.75	12	0.987	Non-rejet de H0
13	13	4.04	13	0.991	Non-rejet de H0
14	14	4.30	14	0.993	Non-rejet de H0
15	15	4.52	15	0.995	Non-rejet de H0
16	16	7.78	16	0.955	Non-rejet de H0
17	17	9.71	17	0.915	Non-rejet de H0
18	18	11.8	18	0.856	Non-rejet de H0
19	19	11.9	19	0.891	Non-rejet de H0
20	20	14.8	20	0.790	Non-rejet de H0
21	21	14.9	21	0.829	Non-rejet de H0
22	22	15.0	22	0.864	Non-rejet de H0
23	23	15.0	23	0.896	Non-rejet de H0
24	24	15.2	24	0.913	Non-rejet de H0
25	25	15.7	25	0.922	Non-rejet de H0
26	26	16.1	26	0.934	Non-rejet de H0
27	27	16.6	27	0.940	Non-rejet de H0
28	28	21.3	28	0.814	Non-rejet de H0

29	29	21.7	29	0.834	Non-rejet de H0
30	30	21.8	30	0.862	Non-rejet de H0
31	31	23.0	31	0.848	Non-rejet de H0
32	32	24.2	32	0.838	Non-rejet de H0
33	33	25.4	33	0.823	Non-rejet de H0
34	34	25.5	34	0.852	Non-rejet de H0
35	35	26.2	35	0.858	Non-rejet de H0
36	36	31.1	36	0.701	Non-rejet de H0
37	37	31.1	37	0.740	Non-rejet de H0
38	38	31.2	38	0.776	Non-rejet de H0
39	39	31.6	39	0.796	Non-rejet de H0
40	40	31.8	40	0.821	Non-rejet de H0
41	41	31.8	41	0.849	Non-rejet de H0
42	42	32.3	42	0.860	Non-rejet de H0
43	43	32.3	43	0.882	Non-rejet de H0
44	44	32.7	44	0.896	Non-rejet de H0
45	45	34.1	45	0.882	Non-rejet de H0
46	46	34.1	46	0.902	Non-rejet de H0
47	47	34.9	47	0.904	Non-rejet de H0
48	48	35.3	48	0.913	Non-rejet de H0

Pour ces 48 premiers lags, l'hypothèse nulle n'est pas rejetée, ce qui indique une absence d'autocorrélation significative des résidus au seuil de 10 %. Le modèle est donc bien spécifié.

Nous testons désormais la significativité de chaque coefficient grâce au test de Bartlett.

```
# Fonction

test_bartlett <- function(modele) {

  T <- length(na.omit(trafmensu))

  # Coefficients du modèle
  coefficients <- modele$coef[
    -length(modele$coef)
  ]

  noms_coefficients <- names(coefficients)

  # Calcul de l'écart-type en utilisant la formule de Bartlett
  ecart_type <- sqrt((1 / T) * (1 + 2 * sum(coefficients^2)))

  # Calcul de la statistique t pour chaque coefficient
```

```

t_stats <- coefficients / ecart_type

valeur_critique <- 1.96

resultats <- tibble(
  nom_coefficient = noms_coefficients,
  coefficient = coefficients,
  ecart_type = ecart_type,
  t_stats = t_stats,
  significativite = ifelse(
    abs(t_stats) > valeur_critique,
    "Significatif",
    "Non significatif"
  )
)

return(resultats)
}

# Test de Bartlett

test_bartlett(sarima_d_trafmensu_sans_t2)

# A tibble: 8 x 5
  nom_coefficient coefficient ecart_type t_stats significativite
  <chr>            <dbl>      <dbl>     <dbl>   <chr>
1 ar1              0.718      0.184     3.91   Significatif
2 ar2              0.512      0.184     2.79   Significatif
3 ar3              -0.636     0.184    -3.47   Significatif
4 ma1              -0.677     0.184    -3.69   Significatif
5 ma2              -0.604     0.184    -3.29   Significatif
6 ma3              0.281      0.184     1.53   Non significatif
7 sar1             -0.00993   0.184    -0.0541 Non significatif
8 sma1             -0.644     0.184    -3.51   Significatif

```

La valeur absolue de la statistique de test est supérieure à 1,96 pour 6 coefficients. L'hypothèse nulle est donc rejetée, ce qui indique que les coefficients ar1, ar2, ar3, ma1, ma2 et sma1 sont significatifs au seuil de 5 %.

En retirant les coefficients ma3 et sar1, nous obtenons un modèle SARIMA(3, 0, 2)(0, 0, 1)<sub>12</sub>.

## 5. Série filtrée via un SARIMA(3, 0, 2)(0, 0, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_d_trafmensu_sans_t3 <- Arima(
  d_trafmensu_sans_t,
  order = c(3,0,2),
  seasonal = list(order = c(0,0,1), period = 12)
)

# Autocorréogrammes
acf_sarima3 <- sarima_d_trafmensu_sans_t3$residuals |>
  ggAcf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("ACF des résidus du modèle SARIMA(3, 0, 2)(0, 0, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
pacf_sarima3 <- sarima_d_trafmensu_sans_t3$residuals |>
  ggPacf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("ACF des résidus du modèle SARIMA(3, 0, 2)(0, 0, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
acf_sarima3
```

ACF des résidus du modèle SARIMA(3, 0, 2)(0, 0, 1)(12)



```
pacf_sarima3
```

ACF des résidus du modèle SARIMA(3, 0, 2)(0, 0, 1)(12)



L'ACF est (légèrement) significativement non nulle aux retards 28 et 36. La PACF est (légèrement) significativement non nulle au retard 36. Il est possible que les résidus ne suivent pas

un bruit blanc et présentent encore de l'autocorrélation.

## 6. Conclusion

Nous retenons le modèle SARIMA(3, 0, 3)(1, 0, 1)<sub>12</sub> dont les résidus suivent davantage un bruit blanc.

## 6. Modélisation en utilisant un modèle de type saisonnier

### 1. Modèle différenciation saisonnière d'ordre 1

```
# Modèle
sarima_trafmensu_sans_t4 <- Arima(
  trafmensu_sans_t,
  order = c(0,0,0),
  seasonal = list(order = c(0,1,0), period = 12)
)

# Autocorrélogrammes
acf_sarima4 <- sarima_trafmensu_sans_t4$residuals |>
  ggAcf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4))+
  ggtitle("ACF des résidus du modèle SARIMA(0, 0, 0)(0, 1, 0)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.


Adding another scale for x, which will replace the existing scale.

```
pacf_sarima4 <- sarima_trafmensu_sans_t4$residuals |>
  ggPacf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("PACF des résidus du modèle SARIMA(0, 0, 0)(0, 1, 0)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```


Scale for x is already present.

Adding another scale for x, which will replace the existing scale.

```
acf_sarima4
```



```
pacf_sarima4
```



Graphiquement, les résidus ne suivent pas un bruit blanc et présentent encore des autocorrélations.

L'ACF est significativement non nulle jusqu'au retard 1, donc  $q = 1$ . L'ACF est significativement non nulle jusqu'au retard saisonnier 1 ( $1 \times 12$ ), donc  $Q = 1$ .

La PACF est significativement non nulle jusqu'au retard 1, donc  $p = 1$ . La PACF est significativement non nulle jusqu'au retard saisonnier 1 ( $3 \times 12$ ), donc  $P = 1$ .

Nous obtenons un modèle SARIMA(1, 0, 1)(1, 1, 1)<sub>12</sub>

## 2. Série filtrée via un SARIMA(1, 0, 1)(1, 1, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_trafmensu_sans_t5 <- Arima(
  trafmensu_sans_t,
  order = c(1,0,1),
  seasonal = list(order = c(1,0,1), period = 12)
)

# Autocorréogrammes
acf_sarima5 <- sarima_trafmensu_sans_t5$residuals |>
  ggAcf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4))+
  ggtitle("ACF des résidus du modèle SARIMA(1, 0, 1)(1, 1, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
pacf_sarima5 <- sarima_trafmensu_sans_t5$residuals |>
  ggPacf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("PACF des résidus du modèle SARIMA(1, 0, 1)(1, 1, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
acf_sarima5
```

ACF des résidus du modèle SARIMA(1, 0, 1)(1, 1, 1)(12)



```
pacf_sarima5
```

PACF des résidus du modèle SARIMA(1, 0, 1)(1, 1, 1)(12)



Graphiquement, les résidus ne suivent pas un bruit blanc et présentent encore des autocorrélations.

Nous allons essayer de déterminer d'autres paramètres p, q, P et Q du modèle SARIMA(p, 0, q)(P, 1, Q)<sub>12</sub> en fonction des graphiques de l'ACF et de la PACF sur les résidus du modèle.

L'ACF est significativement non nulle au retard 3, donc q = 3. La PACF est significativement non nulle retard 3, donc p = 3.

### 3. Série filtrée via un SARIMA(3, 0, 3)(1, 1, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_trafmensu_sans_t6 <- Arima(
  trafmensu_sans_t,
  order = c(3,0,3),
  seasonal = list(order = c(1,0,1), period = 12)
)

# Autocorrélogrammes
acf_sarima6 <- sarima_trafmensu_sans_t6$residuals |>
  ggAcf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("ACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
pacf_sarima6 <- sarima_trafmensu_sans_t6$residuals |>
  ggPacf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("PACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

Scale for x is already present.

Adding another scale for x, which will replace the existing scale.


```
acf_sarima6
```

ACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)



```
pacf_sarima6
```

PACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)



Les résidus suivent un bruit blanc et ne devraient pas présenter d'autocorrélation.

Nous testons la nullité des paramètres estimés pour les différents retards, ainsi que la présence d'autocorrelations significatives à l'aide du test de Ljung-Box.

```
# Test de Ljung-Box sur les résidus pour les 48 premiers lags
```

```
resultat_Ljung_Box2 <- tibble(
  lag = 1:48
) |>
  mutate(
    test_result = map(
      lag,
      ~ Box.test(
        residuals(sarima_trafmensu_sans_t6),
        lag = .x,
        type = "Ljung-Box"
      )
    ),
    X_squared = map_dbl(test_result, ~ .x$statistic),
    df = map_dbl(test_result, ~ .x$parameter),
    p_value = map_dbl(test_result, ~ .x$p.value),
    significativite = ifelse(
      p_value < 0.1,
      "Rejet de H0",
      "Non-rejet de H0"
    )
  ) |>
  select(lag, X_squared, df, p_value, significativite)

print(resultat_Ljung_Box2, n = 48)
```

```
# A tibble: 48 x 5
  lag X_squared     df p_value significativite
  <int>     <dbl> <dbl>   <dbl> <chr>
1     1     0.0309     1    0.860 Non-rejet de H0
2     2     0.0310     2    0.985 Non-rejet de H0
3     3     0.0316     3    0.999 Non-rejet de H0
4     4     0.0921     4    0.999 Non-rejet de H0
5     5     0.687      5    0.984 Non-rejet de H0
6     6     0.706      6    0.994 Non-rejet de H0
7     7     0.803      7    0.997 Non-rejet de H0
8     8     1.40       8    0.994 Non-rejet de H0
```

9	9	1.67	9	0.996	Non-rejet de H0
10	10	3.89	10	0.952	Non-rejet de H0
11	11	3.95	11	0.971	Non-rejet de H0
12	12	4.09	12	0.982	Non-rejet de H0
13	13	4.32	13	0.987	Non-rejet de H0
14	14	4.94	14	0.987	Non-rejet de H0
15	15	4.99	15	0.992	Non-rejet de H0
16	16	8.90	16	0.918	Non-rejet de H0
17	17	10.6	17	0.877	Non-rejet de H0
18	18	12.6	18	0.814	Non-rejet de H0
19	19	12.6	19	0.856	Non-rejet de H0
20	20	15.6	20	0.744	Non-rejet de H0
21	21	16.0	21	0.767	Non-rejet de H0
22	22	16.2	22	0.805	Non-rejet de H0
23	23	16.2	23	0.845	Non-rejet de H0
24	24	17.3	24	0.837	Non-rejet de H0
25	25	18.0	25	0.843	Non-rejet de H0
26	26	19.1	26	0.831	Non-rejet de H0
27	27	19.3	27	0.857	Non-rejet de H0
28	28	23.5	28	0.708	Non-rejet de H0
29	29	23.6	29	0.748	Non-rejet de H0
30	30	23.6	30	0.790	Non-rejet de H0
31	31	25.0	31	0.768	Non-rejet de H0
32	32	26.5	32	0.739	Non-rejet de H0
33	33	28.6	33	0.684	Non-rejet de H0
34	34	28.7	34	0.725	Non-rejet de H0
35	35	29.0	35	0.754	Non-rejet de H0
36	36	31.6	36	0.676	Non-rejet de H0
37	37	31.8	37	0.712	Non-rejet de H0
38	38	31.8	38	0.750	Non-rejet de H0
39	39	33.6	39	0.714	Non-rejet de H0
40	40	34.2	40	0.728	Non-rejet de H0
41	41	34.3	41	0.763	Non-rejet de H0
42	42	34.3	42	0.796	Non-rejet de H0
43	43	34.3	43	0.826	Non-rejet de H0
44	44	34.9	44	0.835	Non-rejet de H0
45	45	38.0	45	0.761	Non-rejet de H0
46	46	38.0	46	0.793	Non-rejet de H0
47	47	38.5	47	0.808	Non-rejet de H0
48	48	39.3	48	0.810	Non-rejet de H0

Pour ces 48 premiers lags, l'hypothèse nulle n'est pas rejetée, ce qui indique une absence d'autocorrélation significative des résidus au seuil de 10 %. Le modèle est donc bien spécifié.

Nous testons désormais la significativité de chaque coefficient grâce au test de Bartlett.

```
# Test de Bartlett

test_bartlett(sarima_trafmensu_sans_t6)

# A tibble: 8 x 5
  nom_coefficient coefficient ecart_type t_stats significativite
  <chr>           <dbl>      <dbl>     <dbl> <chr>
1 ar1              0.720     0.214     3.36 Significatif
2 ar2              0.518     0.214     2.41 Significatif
3 ar3             -0.632     0.214    -2.95 Significatif
4 ma1             -0.695     0.214    -3.24 Significatif
5 ma2             -0.634     0.214    -2.96 Significatif
6 ma3              0.328     0.214     1.53 Non significatif
7 sar1             0.991     0.214     4.62 Significatif
8 sma1            -0.656     0.214    -3.06 Significatif
```

La valeur absolue de la statistique de test est supérieure à 1,96 pour 6 coefficients. L'hypothèse nulle est donc rejetée, ce qui indique que les coefficients ar1, ar2, ar3, ma1, ma2, sar1 et sma1 sont significatifs au seuil de 5 %.

En retirant le coefficient ma3, nous obtenons un modèle SARIMA(3, 0, 2)(1, 1, 1)<sub>12</sub>.

#### 4. Série filtrée via un SARIMA(3, 0, 2)(1, 1, 1)<sub>12</sub> et comportement des résidus

```
# Modèle
sarima_trafmensu_sans_t7 <- Arima(
  trafmensu_sans_t,
  order = c(3,0,2),
  seasonal = list(order = c(1,1,1), period = 12)
)


# Autocorrélogrammes
acf_sarima7 <- sarima_trafmensu_sans_t7$residuals |>
  ggAcf(lag.max = 48) +
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +
  ggtitle("ACF des résidus du modèle SARIMA(3, 0, 2)(1, 1, 1)(12)") +
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5))
```

```
Scale for x is already present.  
Adding another scale for x, which will replace the existing scale.
```

```
pacf_sarima7 <- sarima_trafmensu_sans_t7$residuals |>  
  ggPacf(lag.max = 48) +  
  scale_x_continuous(breaks = seq(0, 48, by = 4)) +  
  ggtitle("PACF des résidus du modèle SARIMA(3, 0, 2)(1, 1, 1)(12)") +  
  theme_bw() +  
  theme(plot.title = element_text(hjust = 0.5))
```


```
Scale for x is already present.  
Adding another scale for x, which will replace the existing scale.
```

```
acf_sarima7
```



```
pacf_sarima7
```

PACF des résidus du modèle SARIMA(3, 0, 2)(1, 1, 1)(12)



L'ACF est (légèrement) significativement non nulle aux retards 28 et 36. Il est possible que les résidus ne suivent pas un bruit blanc et présentent encore de l'autocorrélation.

## 5. Conclusion

Nous retenons le modèle SARIMA(3, 0, 3)(1, 1, 1)<sub>12</sub> dont les résidus suivent davantage un bruit blanc.

## 7. Comparaison des résultats de ces deux modèles

### 1. Modèles

```
# SARIMA(3, 0, 3)(1, 0, 1)(12)
sarima_d_trafmensu_sans_t2
```

Series: d\_trafmensu\_sans\_t  
ARIMA(3,0,3)(1,0,1)[12] with non-zero mean

Coefficients:  
ar1      ar2      ar3      ma1      ma2      ma3      sar1      sma1

```

  0.7179  0.5119 -0.6365 -0.6773 -0.6038  0.2811 -0.0099 -0.6436
s.e.  0.1743  0.2657  0.1536  0.2031  0.2904  0.1874  0.1353  0.1194
      mean
      -0.0117
s.e.  0.0286

sigma^2 = 129.6: log likelihood = -594.87
AIC=1209.74   AICc=1211.28   BIC=1240.11

```

```
# SARIMA(3, 0, 3)(1, 1, 1)(12)
sarima_trafmensu_sans_t6
```

Series: trafmensu\_sans\_t  
ARIMA(3,0,3)(1,0,1)[12] with non-zero mean

Coefficients:

ar1	ar2	ar3	ma1	ma2	ma3	sar1	sma1
0.7202	0.5177	-0.6324	-0.6947	-0.6336	0.3283	0.9908	-0.6564
s.e.	0.1704	0.2468	0.1409	0.2001	0.2704	0.1788	0.0057
	mean						
	0.0316						
s.e.	0.0741						


```
sigma^2 = 127.7: log likelihood = -648.75
AIC=1317.49   AICc=1318.91   BIC=1348.61
```

Le modèle SARIMA(3, 0, 3)(1, 0, 1)<sub>12</sub> est le meilleur selon les critères AIC et BIC qui sont plus faibles.

## 2. Autocorréogrammes : ACF


```
acf_sarima2
```

ACF des résidus du modèle SARIMA(3, 0, 3)(1, 0, 1)(12)



```
acf_sarima6
```


ACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)



Les deux ACF des résidus correspondent à ceux de bruit blanc.


### 3. Autocorréogrammes partiels : PACF

```
pacf_sarima2
```



```
pacf_sarima6
```

PACF des résidus du modèle SARIMA(3, 0, 3)(1, 1, 1)(12)



Le PACF du modèle SARIMA(3, 0, 3)(1, 1, 1)<sub>12</sub> est légèrement significatif aux retards 16 et 44.

## 6. Conclusion

Nous retenons le modèle SARIMA(3, 0, 3)(1, 0, 1)<sub>12</sub>, dont la différenciation saisonnière a été effectuée au préalable, notamment parce que son AIC et son BIC sont plus faibles.

## 8. Conclusion

### 1. On sépare notre tendance en deux périodes de temps.

```
# Propriétés de la série
start(trafmensu) # La série commence en janvier 1993
```

```
[1] 1993     1
```

```
end(trafmensu) # La série se termine en octobre 2007
```

```
[1] 2007     10
```

```

frequency(trafmensu) # La série est mensuelle


[1] 12

# Série avant septembre 2001
trafmensu_avant_sept2001 <- window(trafmensu, start = c(1993, 1), end = c(2001, 08))

# Série après septembre 2001
trafmensu_apres_sept2001 <- window(trafmensu, start = c(2001, 9))

# Affichage
plot(trafmensu_avant_sept2001, main = "Série avant septembre 2001", col = "blue")

```




```

plot(trafmensu_apres_sept2001, main = "Série après septembre 2001", col = "red")

```


## Série après septembre 2001



```
# Décomposition
decomp_trafmensu_avant_sept2001 <- decompose(
  trafmensu_avant_sept2001,
  type = "additive"
)

# Affichage
plot(decomp_trafmensu_avant_sept2001)
```


## Decomposition of additive time series



```
# Décomposition
decomp_trafmensu_apres_sept2001 <- decompose(
  trafmensu_apres_sept2001,
  type = "additive"
)

# Affichage
plot(decomp_trafmensu_apres_sept2001)
```

## Decomposition of additive time series



## 2. On sépare notre modèle en deux périodes de temps.


```
# Récupération des valeurs ajustées sous forme de série temporelle
fitted_sarima <- ts(
  fitted(sarima_d_trafmensu_sans_t2),
  start = start(trafmensu),
  frequency = frequency(trafmensu)
)

# Modèle avant septembre 2001
sarima_avant_sept2001 <- window(
  fitted_sarima, start = c(1993, 1), end = c(2001, 08)
)

# Modèle après septembre 2001
sarima_apres_sept2001 <- window(
  fitted_sarima, start = c(2001, 9)
)


# Affichage
plot(sarima_avant_sept2001, main = "Estimation avant septembre 2001", col = "blue")
```

### **Estimation avant septembre 2001**



```
plot(sarima_apres_sept2001, main = "Estimation après septembre 2001", col = "red")
```

### **Estimation après septembre 2001**



## Series finales

```
trafmensu_avant_septembre2001 <-
  decomp_trafmensu_avant_sept2001$trend + sarima_avant_sept2001

trafmensu_apres_septembre2001 <-
  decomp_trafmensu_apres_sept2001$trend + sarima_apres_sept2001
```